

LangChain Models Component

LangChain-এর Models Component আসলে কী?

ধরো, তুমি বিভিন্ন AI Model ব্যবহার করতে চাও।

যেমন:

- OpenAI এর GPT
- Google এর Gemini
- Anthropic এর Claude
- Hugging Face এর Open Source Models

সমস্যা হলো, প্রত্যেক কোম্পানির API এবং কোড লেখার নিয়ম আলাদা।

উদাহরণ:

OpenAI-এর জন্য এক ধরনের কোড লিখতে হবে, Gemini-এর জন্য অন্য ধরনের, Claude-এর জন্য আবার অন্য ধরনের।

LangChain এখানে একটি "Common Interface" তৈরি করে দেয়।

অর্থাৎ তুমি যদি LangChain ব্যবহার করো, তাহলে প্রায় একই ধরনের কোড লিখে বিভিন্ন AI Model ব্যবহার করতে পারবে।

সহজ ভাষায়:

LangChain = AI Model গুলোর জন্য Universal Remote Control

যেভাবে একটি ইউনিভার্সাল রিমোট দিয়ে বিভিন্ন টিভি চালানো যায়, ঠিক সেভাবেই LangChain দিয়ে বিভিন্ন AI Model চালানো যায়।

LangChain-এ Model কত ধরনের?

মূলত ২ ধরনের Model নিয়ে কাজ করা হয়।

১. Language Model

এগুলো Text Input নেয় এবং Text Output দেয়।

উদাহরণ:

Input:

What is the capital of India?

Output:

New Delhi

অর্থাৎ প্রশ্ন দিলে উত্তর দেয়।

এগুলো সাধারণ ChatGPT-এর মতো কাজ করে।

২. Embedding Model

এটা একটু ভিন্ন।

এখানে Text Input দিলে Text Output আসে না।

বরং অনেকগুলো সংখ্যা (Vector) আসে।

উদাহরণ:

"I love cricket"

Output:

[0.12, 0.45, -0.21, 0.88, ...]

এগুলোকে Embedding Vector বলা হয়।

Embedding কেন দরকার?

কম্পিউটার মানুষের মতো ভাষার অর্থ বুঝতে পারে না।

তাই শব্দ বা বাক্যের অর্থকে সংখ্যায় রূপান্তর করা হয়।

যেমন:

Virat Kohli
Cricket Player

এই দুইটা বাক্যের অর্থ কাছাকাছি।

তাই Embedding Vector-ও কাছাকাছি হবে।

আবার,

Virat Kohli
Pizza Recipe

এদের অর্থ আলাদা।

তাই Embedding Vector-ও অনেক দূরে থাকবে।

এই ধারণার উপর ভিত্তি করে:

- Semantic Search
- Recommendation System
- RAG Application
- Document Search

তৈরি করা হয়।

Language Model-এর আবার দুইটা ধরন আছে

১. LLM (Large Language Model)

পুরনো ধরনের Text Model।

এগুলো:

Text নেয় → Text দেয়

উদাহরণ:

Input:

Summarize this article

Output:

This article discusses...

এখানে শুধু Plain Text নিয়ে কাজ হয়।

Conversation-এর ধারণা থাকে না।

২. Chat Model

বর্তমানে সবচেয়ে বেশি ব্যবহৃত।

ChatGPT, Gemini, Claude — প্রায় সব আধুনিক Model Chat Model।

এগুলো Message আকারে Input নেয়।

উদাহরণ:

```
[  
  {"role": "system", "content": "You are a doctor"},  
  {"role": "user", "content": "I have fever"}  
]
```

এখানে Role খুব গুরুত্বপূর্ণ।

System Role

মডেলকে নির্দেশনা দেয়।

উদাহরণ:

You are a doctor

অথবা

You are a Python expert

User Role

ব্যবহারকারীর প্রশ্ন।

উদাহরণ:

How to reduce fever?

Assistant Role

AI-এর পূর্বের উত্তর।

Conversation History সংরক্ষণ করতে ব্যবহৃত হয়।

উদাহরণ:

Take proper rest and drink water.

Chat Model-এর সুবিধা

Conversation মনে রাখতে পারে

উদাহরণ:

User:

My name is Rahim

Assistant:

Nice to meet you.

User:

What is my name?

Model উত্তর দিতে পারবে:

Your name is Rahim.

কারণ আগের Message-গুলো Context হিসেবে থাকে।

Closed Source Model কী?

এগুলো কোম্পানির নিজস্ব Model।

তুমি শুধু API ব্যবহার করতে পারবে।

ভিতরের Training Data বা Model Weight দেখতে পারবে না।

উদাহরণ:

- GPT
- Claude
- Gemini

সুবিধা

সাধারণত:

- বেশি Powerful
- বেশি Accurate
- ভালো Reasoning
- দ্রুত উন্নত হয়

অসুবিধা

API Cost লাগে।

উদাহরণ:

প্রতিবার Request পাঠালে টাকা কাটা হবে।

অনেক User থাকলে Cost দ্রুত বেড়ে যায়।

Open Source Model কী?

এখানে Model Download করে নিজের Computer বা Server-এ চালানো যায়।

উদাহরণ:

- TinyLlama
- Llama
- Mistral
- Gemma

সুবিধা

১. API Cost নেই

একবার Model Download করলেই হলো।

২. Data Privacy বেশি

তোমার Data OpenAI বা Google-এর Server-এ যাবে না।

সবকিছু Local Machine-এ Process হবে।

যেসব কোম্পানি Sensitive Data নিয়ে কাজ করে, তারা প্রায়ই Open Source Model ব্যবহার করে।

অসুবিধা

- নিজের Hardware দরকার
- GPU দরকার হতে পারে
- Performance অনেক সময় GPT-এর চেয়ে কম হয়

Temperature Parameter কী?

এটা Model কতটা Creative হবে তা নিয়ন্ত্রণ করে।

Temperature = 0

খুব নির্দিষ্ট উত্তর।

একই প্রশ্ন করলে প্রায় একই উত্তর পাওয়া যাবে।

উদাহরণ:

$$2 + 2 = ?$$

সবসময়:

4

Temperature = 1

সামান্য Creative।

Temperature = 1.5+

অনেক বেশি Random এবং Creative।

উদাহরণ:

"একটা গল্প লেখো"

প্রতিবার ভিন্ন গল্প আসতে পারে।

কখন কোনটা ব্যবহার করব?

Coding

Temperature = 0

কারণ সঠিক উত্তর দরকার।

Math

Temperature = 0

Creative Writing

Temperature = 1 বা তার বেশি

Max Completion Tokens কী?

এটা বলে দেয় Model সর্বোচ্চ কত বড় উত্তর দিতে পারবে।

উদাহরণ:

`max_tokens = 100`

তাহলে AI ১০০ টোকেনের বেশি লিখতে পারবে না।

কেন ব্যবহার করা হয়?

Cost Control

বড় Response মানে বেশি Token।

বেশি Token মানে বেশি টাকা।

Response Limit

যখন ছোট উত্তর প্রয়োজন হয়।

যেমন:

এক লাইনে উত্তর দাও।

সবচেয়ে গুরুত্বপূর্ণ অংশ: Document Similarity

এখানে Embedding ব্যবহার করে Document Search দেখানো হয়েছে।

ধরো তোমার কাছে ১০০০টা Document আছে।

User প্রশ্ন করলো:

Virat Kohli সম্পর্কে বলো

এখন ১০০০টা Document AI-কে পাঠানো সম্ভব না।

কারণ:

- Cost বেশি
- Speed কম

তাই প্রথমে Embedding তৈরি করা হয়।

ধাপ ১

সব Document-এর Embedding তৈরি করা হয়।

উদাহরণ:

Document 1 → Vector

Document 2 → Vector

Document 3 → Vector

ধাপ ২

User Query-এরও Embedding তৈরি করা হয়।

"Tell me about Virat Kohli"

→ Vector

ধাপ ৩

Cosine Similarity ব্যবহার করে দেখা হয় কোন Document-এর Vector সবচেয়ে কাছাকাছি।

Cosine Similarity কী?

এটা দুইটা Vector কতটা Similar সেটা মাপে।

মান সাধারণত:

1 = সম্পূর্ণ মিল

0 = কোনো মিল নেই

-1 = বিপরীত অর্থ

উদাহরণ:

Virat Kohli
Indian Cricketer

Similarity:

0.95

খুব বেশি মিল।

Virat Kohli
Pizza Recipe

Similarity:

0.08

খুব কম মিল।

তারপর সবচেয়ে Relevant Document বের করে AI-কে দেওয়া হয়।

AI সেই Document পড়ে উত্তর দেয়।

এটাই আধুনিক RAG (Retrieval Augmented Generation)-এর মূল ভিত্তি।